本科生毕业论文（设计）

题目：基于 Transformer 的灵巧机器人的动作重定向技术研究

姓　　名　梁子彦

学　　号　22308097

院　　系　电子与通信工程学院

专　　业　电子信息科学与技术

指导教师　高庆 副教授

2026 年 3 月 25 日

基于 Transformer 的灵巧机器人的动作重定向技术研究

Technology Research on Motion Retargeting Methods based on Transformer

姓　　名	梁子彦
学　　号	22308097
院　　系	电子与通信工程学院
专　　业	电子信息科学与技术
指导教师	高庆 副教授

2026 年 3 月 25 日

表二　毕业论文过程检查记录表

毕业论文过程检查记录表
指导教师分阶段检查论文的进展情况（要求过程检查记录不少于 3 次）
第一次检查 学生总结： 　　在这一阶段，XXX 工作基本完成，主要在如下几个方面： 指导教师意见： 　　论文完成情况良好。
第二次检查 学生总结： 　　… 指导教师意见： 　　…
第三次检查 学生总结： 　　… 指导教师意见： 　　…
第四次检查 学生总结： 　　… 指导教师意见： 　　…
学生签名:　　年　月　日 指导教师签名:　　年　月　日

(续表)	
总体完成情况	指导教师意见： 1、按计划完成，完成情况优秀：（　） 2、按计划完成，完成情况良好：（　） 3、按计划完成，完成情况中等：（　） 4、基本按计划完成，完成情况及格：（　） 5、完成情况不及格：（　） 指导教师签名: 日期：

学术诚信声明

本人郑重声明：所呈交的毕业论文（设计），是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文（设计）不包含任何其他个人或集体已经发表或撰写过的作品成果。对本论文（设计）的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本论文（设计）的知识产权归属于培养单位。本人完全意识到本声明的法律结果由本人承担。

作者签名:

日　　期：　　年　　月　　日

论文题目： 基于 Transformer 的灵巧机器人动作重定向技术研究
专　　业： 电子信息科学与技术
姓　　名： 梁子彦
学　　号： 22308097
指导教师： 高庆 副教授

摘要

人机运动重定向作为连接人类运动空间与机器人操作空间的桥梁，已成为具身智能领域实现高灵巧数据生成生产的核心关键技术。特别是在涉及复杂物体交互与精密抓取的场景中，如灵巧机械手的远程遥操作，在这方面重定向技术的精度与实时性直接决定了系统的工作效率。为了提高重定向结果的精度和平滑性，我们认为可以引入时间信息作为重定向算法输入之一。现有主流研究多侧重于单帧映射模型，这类方法由于缺乏对运动连续性的考虑，往往忽略了关键的帧间时序依赖关系，导致生成的机器人动作在执行过程中出现明显的轨迹抖动与不连贯现象，严重影响了重定向结果的平滑性与物理可行性。

针对上述挑战，本文提出了 TransRetarget：一种基于时空 Transformer 架构的新型多帧人手到机械手运动重定向算法。该方法充分利用 Transformer 架构在长序列建模与全局特征提取方面的卓越能力，构建了一个能够深度融合空间结构与时间维度的特征提取网络。通过该架构，模型不仅能够精准建模单帧内各手指关节间的复杂解剖学相关性，更能够捕捉连续多帧数据中的动态时间演变规律。这种对时空特征的联合建模，确保了从人类手部姿势到机械手动作映射的高保真度，从而生成既符合人类运动意图又具备物理平滑性的高质量机械手运动轨迹。为进一步确保人类手部姿势与异构机械手动作之间的一致性，本文针对性地设计了一套严谨的几何约束与运动学辅助损失函数机制。我们将手指侧向移动、手指弯曲度以及核心指尖间距等关键解剖特征进行参数化建模，并将其整合为一个多目标的复合损失函数。该损失函数旨在对多个方面进行损失计算，使得网络得以进行自监督，鼓励模型在训练过程中学习到跨空间的语义对齐特征，有效解决了人机手部异构性带来的映射问题。

本工作在多个大规模人手运动数据集及使用多种主流灵巧机械手在虚拟平台上进行了详尽的对比实验。实验结果一致表明，TransRetarget 在重定向精度、运动轨迹平滑度以及跨平台泛化性等核心指标上均显著优于现有的基准模型。实验证明，本文提出的时空建模方案与复合损失机制能够有效支撑复杂的具身智能交互任务，为高精度灵巧遥操作提供了可靠的技术方案。另外本工作还通过丰富的实验结果表明，我们的方法在多个数据集和各种灵巧机械手平台上均取得了卓越的性能。

关键词： Transformer，动作重定向，时空域特征，灵巧手

Title: Technology Research on Motion Retargeting Methods
Major: Electronic Information Science and Technology
Name: Ziyan Liang
Student ID: 22308097
Supervisor: Associate Prof. Qing Gao

ABSTRACT

Human-robot motion retargeting, as a bridge connecting the human motion space with the robot operation space, has become a core and key technology for achieving high-fidelity data generation and production in the field of embodied intelligence. Especially in scenarios involving complex object interaction and precise grasping, such as the remote teleoperation of dexterous manipulators, the accuracy and real-time performance of retargeting technology directly determine the system's operational efficiency. To enhance the accuracy and smoothness of the retargeting results, we propose incorporating temporal information as one of the inputs to the retargeting method. Current mainstream research mostly focuses on single-frame mapping models. These methods, due to the lack of consideration for motion continuity, often overlook the crucial inter-frame temporal dependencies, resulting in obvious trajectory jitter and discontinuity in the generated robot motions during execution, which significantly affects the smoothness and physical feasibility of the retargeting results.

In response to the aforementioned challenges, this paper proposes TransRetarget: a novel multi-frame human-robot hand motion retargeting method based on the spatial-temporal Transformer architecture. This method fully utilizes the outstanding capabilities of the Transformer architecture in long sequence modeling and global feature extraction, constructing a feature extraction network that can deeply integrate spatial structure and time dimensions. Through this architecture, the model not only can accurately model the complex anatomical correlations among each finger joint in a single frame, but also can capture the dynamic time evolution patterns in consecutive multiple frames of data. This joint modeling of spatiotemporal features ensures high fidelity in mapping from human hand postures to mechanical hand actions, thereby generating high-quality mechanical hand motion trajectories that both conform to human movement intentions and possess physical smoothness. To further ensure the consistency between human hand postures and heterogeneous mechanical hand actions, this paper specifically designs a rigorous geometric constraint and kinematics auxiliary loss function mechanism. We parameterize and model key anatomical features such as finger lateral movement, finger curvature, and core fingertip spacing, and integrate them into a multi-objective composite loss function. This loss function aims to calculate losses in multiple aspects, enabling the network to perform self-supervision and encouraging the model to learn cross-space semantic align-

ment features during training, effectively solving the mapping problem caused by the heterogeneity of human and mechanical hands.

In this work, extensive comparative experiments were conducted across multiple large-scale human hand motion datasets and various mainstream dexterous robotic hands on virtual platforms. Experimental results consistently demonstrate that TransRetarget significantly outperforms existing baseline models in core metrics such as retargeting accuracy, motion trajectory smoothness, and cross-platform generalization. Experiments prove that the proposed spatiotemporal modeling scheme and composite loss mechanism can effectively support complex embodied intelligence interaction tasks, providing a reliable technical solution for high-precision dexterous teleoperation. Furthermore, this work demonstrates through rich experimental results that our method achieves superior performance across multiple datasets and various dexterous robotic hand platforms.

Keywords: Transformer, Motion Retargeting, Spatio-Temporal Features, Dextrous Hands

目录

第 1 章 绪论 1
1.1 选题背景与意义 1
1.2 国内外研究现状和相关工作 1
1.3 本文的研究内容与主要工作 3
1.4 本文的论文结构与章节安排 4

第 2 章 相关工作 5
2.1 运动重定向 5
2.2 基于优化的方法 6
2.3 基于学习的方法 7
2.4 结合了优化与学习的方法 9
2.5 时间信息的重要性 10
2.6 Transformer 架构简述 10
2.7 Transformer 架构在人体骨骼点序列中的应用 11
2.8 本章小结 14

第 3 章 基于时空 Transformer 的运动重定向方法 15
3.1 PoseformerV1 15
3.2 空间编码器 16
3.3 时间编码器 17
3.4 回归头 18
3.5 运动学模块 19
3.6 损失函数设计 20
3.7 本章小结 22

第 4 章 实验部分 23
4.1 实验配置 23
4.2 不同方法的对比实验 28
4.3 本方法消融实验 28
4.4 Transformer 结构作用可视化 29
4.5 多平台实验 29
4.6 单机现实世界测试 30

4.7 本章小结 31

第 5 章 重定向后的交互强化 32

5.1 直接重定向结果的缺陷 32

5.2 基于 VLM 的目标抓取力预测 32

5.3 基于力矩反馈的强化学习 32

第 6 章 总结与展望 34

6.1 工作总结 34

6.2 研究展望 34

参考文献 36

致谢 38

第 1 章 绪论

1.1 选题背景与意义

人机运动重定向是指将人类动作序列从人的关节运动空间映射到机器人运动空间的过程，旨在解决两者的物理结构、运动学约束以及自由度配置之间的差异。该技术可根据应用需求分为实时重定向与离线重定向：实时重定向是机器人遥操作技术的核心，广泛应用于远程手术等需要精密操作的场景；而离线重定向则在机器人数据采集领域扮演着愈发重要的角色。随着具身智能的飞速发展，高质量、规模化的机器人动作数据已成为驱动大模型训练的基础，因此机器人数据采集工作也变得变得重要。

而在对于机器人的数据采集来说，灵巧手的数据精度要求更高。同时，灵巧手自由度远比其他部位高，使得重定向算法在处理空间映射时面临极大的复杂性。在机器人系统中，灵巧手作为与环境交互的主要末端执行器，其控制精度直接影响任务的完成质量。另一方面，由于不同厂商生产的灵巧手在机械构造和自由度上存在显著异构性，开发一种具有平台兼容性且能适配多种灵巧手模型的通用算法具有重要的工程价值。

目前，现有的优化方法或基于学习的方法虽然在速度或特定任务的精度上取得了进展，但大多仅关注单帧数据的映射，忽略了连续输入帧之间的时序相关性。这种局限性导致生成的机器人动作序列在物理执行时缺乏平滑性，极易受到视觉捕捉噪声的干扰而产生抖动。在灵巧手的运动重定向之中，应该要考虑时序信息，以提升重定向的精度。因此，研究并开发一种能够深度提取输入序列时空特征、具备高精度、强实时性且兼顾泛化性能的运动重定向框架，对于推动具身智能的数据获取效率及提升灵巧遥操作系统的稳定性具有重要的理论意义与应用前景[1][2]。

1.2 国内外研究现状和相关工作

1.2.1 基于优化的运动重定向方法

早期的运动重定向研究主要依赖于数值优化算法。这类方法通过建立源域与目标域之间的运动学映射方程，并在逆运动学框架下施加关节限位、自碰撞检测及平滑度约束，寻找每个时刻的最优关节解。例如，Qin 等人提出的 AnyTeleop 框架利用统一的运动学映射实现了较好的实时性与平台泛化能力[3]。然而，基于优

化的方法通常依赖于简化的数学模型，在处理高度异构的非线性映射时，容易陷入局部最优解，导致在复杂抓取任务中的重定向精度受限。

1.2.2 基于学习的运动重定向方法

随着深度学习技术的演进，越来越多的研究者转向数据驱动的方法。通过构建深层神经网络，模型能够直接学习从人手姿态到机器人关节空间的复杂非线性映射。这类方法通过增加模型参数量，显著提升了重定向的精度与对噪声的鲁棒性。例如，Figuera 等人通过重新定义数据配对方式，强化了模型对精细动作的捕捉[4]。然而，纯学习方法通常面临泛化性挑战，即针对特定机器人型号训练的模型难以直接部署到其他异构平台上。此外，随着模型规模的增大，其推理延迟往往会增加，给实时遥操作任务带来挑战。

1.2.3 优化与学习结合的混合方法

为了兼顾重定向的速度、精度与通用性，近年来的研究开始探索将学习结合优化的混合框架。这类方法通常利用神经网络快速预测初始姿态，再结合优化层进行运动学约束校准，从而在保证精度的同时提升跨平台的适配能力[5]。尽管如此，上述方法大多将重定向任务视作单帧映射问题，在实际运行过程中未能有效提取连续输入帧之间的时空相关信息。由于缺乏帧间依赖关系的建模，生成的机器人动作序列在面对视觉捕捉抖动或环境噪声时，往往缺乏必要的平滑度，导致物理执行器的机械磨损加剧且操作体验不佳。

1.2.4 Transformer 在时序特征提取中的应用

Transformer 架构凭借其强大的自注意力机制和并行计算能力，在自然语言处理及计算机视觉领域取得了突破性进展[6]。在智能机器人方面，Transformer 已开始应用于人体骨骼序列建模，用于捕捉复杂的运动轨迹规律。相比于传统的循环神经网络（RNN），Transformer 能够更有效地处理长距离依赖关系。另外也有研究使用 Transformer 架构来将二维人体姿态序列升维至三维人体序列，展示了其对三维姿态序列的建模能力。受此启发，在本研究中，我们引入时空 Transformer 架构来处理连续的人手三维运动序列，旨在通过建模帧间的时间依赖性与帧内的空间关联性，从根本上解决单帧重定向带来的动作不稳定问题, 提高重定向轨迹的平滑度。

1.3 本文的研究内容与主要工作

本文旨在针对灵巧机器人动作重定向中存在的时空特征提取不足、动作不平滑等问题，提出并实现一种基于时空 Transformer 架构的通用重定向框架 TransRetarget。具体研究内容与主要工作如下：

1.3.1 基于时空 Transformer 的重定向模型架构设计

本文设计并实现了一种全新的多帧输入重定向网络。通过引入 Transformer 编码器，利用自注意力机制同时对人手动作序列进行空间维度（帧内关节相关性）和时间维度（帧间时序依赖性）的特征建模。该架构改变了传统方法逐帧推理的模式，能够有效识别并抑制输入信号中的瞬时噪声与抖动，从而生成高平滑度的机器人动作指令。

1.3.2 面向自监督学习的多准则复合损失函数构建

为了实现高精度的动作对齐，本文设计了一套综合运动学特征约束的复合损失函数系统。该系统整合了手指侧向移动损失、手指弯曲度一致性损失以及关键指尖间距约束。通过在特征空间内最小化人手向量与机器人手向量的差异，强制模型学习到具有物理语义的一致性映射，显著提升了生成动作的自然度与抓取准确性。

1.3.3 跨平台泛化性与实时控制系统实现

本文构建了一个具备高通用性的软件框架，能够适配多种异构灵巧手模型。通过引入归一化参数，解决了不同硬件间自由度配置与物理比例不一致的问题。同时，针对实时遥操作场景优化了模型推理逻辑，确保了算法在保持高精度的前提下，具备极低的计算延迟，满足实时交互控制的需求。

1.3.4 实验验证与性能评估

本文在一个公开数据集和一个使用实验室器材自行采集的 VisionPro 动捕数据集上进行了充分的实验验证。通过与现有基于优化、基于学习以及混合策略的基准算法进行对比，从重定向误差、轨迹平滑度、计算效率及跨平台成功率等多个维度评估了 TransRetarget 的优越性。此外，本文还开展了消融实验，验证了各项损失函数对系统最终性能的贡献。

1.4 本文的论文结构与章节安排

本文共分为五章，各章节内容安排如下：

第一章为绪论，介绍了研究背景、意义、国内外研究现状以及本文的主要工作和章节安排。

第二章为相关工作，详细回顾了运动重定向领域的经典方法与最新进展，并分析了现有方法的优缺点。同时介绍了 Transformer 架构的基本原理与实现方法，以及其在人体骨骼序列中的应用。

第三章为方法设计，系统阐述了基于时空 Transformer 的重定向模型架构、损失函数设计。

第四章为实验与结果，展示了在多个数据集上的实验设置、评估指标以及与基准方法的对比结果，并通过消融实验分析了各模块的贡献。

第五章为重定向结果的交互强化，探讨了如何在得到重定向结果后，实时交互的同时进行合理修正，以强化交互效果。

第六章为总结与展望，总结了本文的研究工作与主要贡献，并对未来的研究方向进行了展望。

第 2 章 相关工作

本章内容概括人机重定向相关研究内容，并介绍现有人机重定向算法原理，主要分为基于优化的方法、基于学习的方法以及优化与学习结合的混合方法这三类进行介绍。同时介绍 Transformer 架构和其在人体骨骼点序列里面的应用。

2.1 运动重定向

人机运动重定向是指将源域中的人类运动序列映射到目标域中具有不同物理结构、运动学约束和自由度配置的机器人上，这一过程可以是实时的，也可以是离线的。实时人机运动重定向是机器人遥操作技术的核心，主要用于需要精确机器人操作的场景，例如远程手术。而离线人机运动重定向则主要用于机器人数据采集场景，随着具身人工智能的发展，这一领域近年来越来越受欢迎。对于机器人而言，主要负责交互的部分是机械手，理想的重定向方法应具有平台兼容性，能够适应各种型号的灵巧机械手，以便不同制造商的用户都能方便使用。此外，由于机械手具有更多的自由度，因此手部运动重定向方法往往更为复杂[7]。因此，开发一种准确、高效且通用的人机手部动作重定向框架已成为一项关键的研究挑战。

近年来，众多研究致力于解决上述挑战。如图 2-1(a) 所示, 一些研究采用基于优化的方法，例如一项使用统一运动学映射进行实时优化的研究，这种方法速度快且平台通用性好，但由于数学模型简化和局部解的存在，精度有所欠缺[3]。一些研究人员转向基于学习的方法，如图 2-1(b) 所示，这种方法提高了重定向精度，但因增加模型参数容量而缺乏速度和平台通用性[4]。为了同时提高重定向速度、精度和平台通用性，研究提出了结合优化和学习的方法[8]，如图 2-1(c) 所示。然而，在上述方法中，都仅使用单帧数据进行重定向，在其操作过程中未提取连续输入帧之间的帧间相关性信息，因此生成的机器人动作序列缺乏流畅性。

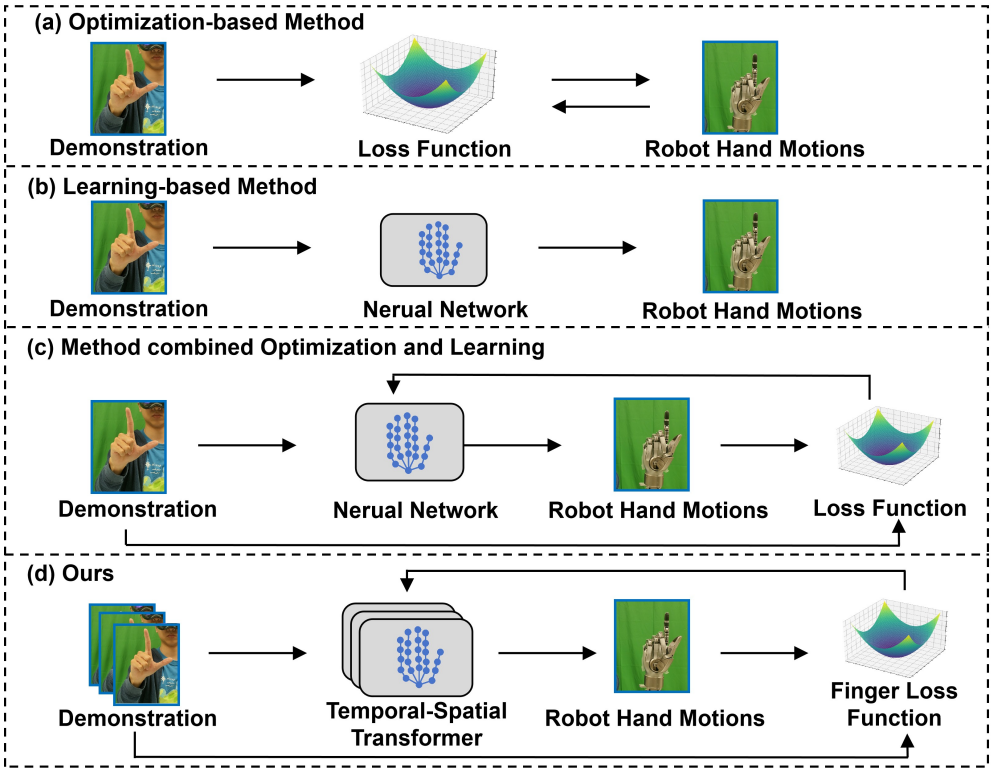

图 2-1 Illustration of different motion retargeting methods. (a) Optimization-based method; (b) Learing-based method; (c) Method combining optimization and learning; (d) Ours.

2.2 基于优化的方法

2.2.1 基本原理

基于优化的算法将人机运动重定向视为一个在特定约束条件下的数学寻优问题。其核心逻辑是构建一个目标函数，通过数学求解器在每一帧数据中计算出一组机器人关节角度，使得机器人的末端执行器与人类手部对应关键点之间的欧式距离最小化。该类方法通常基于逆运动学理论。求解过程通常涉及指定精度的迭代计算。给定人类手部的关键点坐标序列 $H = \{h_1, h_2, \ldots, h_n\}$，目标是求解机器人关节角度矢量 θ，使得机器人的末端执行器位置 $f(\theta)$ 与对应的人类关键点 h 之间的距离函数 D 最小化。其标准的数学表达形式如下：

$$\min_{\theta} \|f(\theta) - \phi(h)\|^2 + \lambda R(\theta)$$

其中，ϕ 为空间映射函数，$R(\theta)$ 为正则化项（如关节速度平滑约束或偏离标准姿态的惩罚项），λ 为平衡系数。

2.2.2 基于重投影的实时优化 (AnyTeleop)

AnyTeleop 是一种典型的基于视觉观测和实时优化的重定向框架。它通过构建统一的运动学流形，将不同结构的灵巧手映射到同一参数空间中。该方法利用高性能求解器在极短的时间内完成逆向寻优，其最大的特点是无需离线预训练，即可实现从单目相机输入到异构灵巧手动作的实时转换。

2.2.3 基于能量函数的全身映射

另一类著名方法侧重于全局一致性，通过设计复杂的能量函数来描述人机之间的位姿相似度。这类方法不仅考虑末端位置的对齐，还引入了关节限位、自碰撞规避以及重心平衡等物理约束。例如，在早期的类人机器人重定向研究中，研究者通过拉格朗日乘子法处理等式与不等式约束，确保了机器人在追踪人类动作时的物理稳定性。

2.2.4 优化方法的优缺点

优点：平台无关性：算法逻辑基于通用的运动学描述，能够快速适配不同自由度（DoF）配置的机器人平台。无需训练数据：不需要大规模的手动标注数据集，极大降低了系统的前期开发成本。物理准确性：通过显式添加硬约束，可以严格保证生成的动作不超出机器人的机械极限。

缺点：局部最优陷阱：受限于非线性优化的本质，求解器容易收敛至局部极小值，导致生成的动作出现不连续的跳变。计算开销与精度的矛盾：为了提高实时性，往往需要限制迭代次数，这会直接导致末端映射的精度下降。时序平滑度缺失：由于该类方法多针对单帧进行独立优化，忽略了动作的内在惯性，输出序列往往存在高频抖动

2.3 基于学习的方法

2.3.1 基本原理

基于学习的方法利用深度神经网络强大的非线性拟合能力，试图直接建立从人类手部姿态特征空间到机器人关节角度空间（或控制参数空间）的映射函数。

该类方法的核心思想是将重定向任务建模为回归问题。通过构建深度神经网络（如多层感知机 MLP 或卷积神经网络 CNN），在海量的人机动作配对数据集上

进行监督学习或自监督学习。其基本数学形式可以表示为：

$$\theta = \mathcal{N}(H; \omega)$$

其中，H 为输入的人手关键点特征向量，ω 为待优化的网络参数。在训练过程中，通过定义相似度损失函数（Similarity Loss）和物理约束损失，引导网络自动提取人手运动中的高维语义信息，并将其转化为目标机器人的运动指令。

2.3.2 基于重定向网络的手部映射

DexPilot 是一种代表性的数据驱动重定向框架。它利用深度学习模型从单目视觉输入中提取人手姿态，并采用点云匹配或关键点回归的方式，将复杂的指尖运动映射到高自由度的灵巧手上。该方法的突出特点是利用大规模的合成数据集进行预训练，使得系统在处理光照变化和遮挡时表现出极强的鲁棒性，能够实现高精度的实时灵巧操作。

2.3.3 跨域语义对齐映射 (TeachNet)

TeachNet 引入了端到端的学习思路，通过设计一种视觉识别与重定向协同优化的架构，解决了人手与机器人手形状异构带来的特征失配问题。该方法通过构建共享的特征嵌入空间，强制模型学习人手关键点与机器人指尖之间的几何对应关系。TeachNet 证明了在大规模数据驱动下，模型可以绕过复杂的解析解算，直接输出符合人类意图的平滑抓取动作。

2.3.4 优缺点

优点：推理速度极快：模型训练完成后，前向传播的计算开销极低，能够轻松满足数百赫兹（Hz）的实时控制需求。鲁棒性强：在面对视觉输入噪声、关键点缺失或部分遮挡时，深度模型通常具有比几何优化更好的容错能力。精度上限高：通过增加模型参数量和训练数据多样性，可以捕捉到优化方法难以建模的复杂动作细节。

缺点：泛化性能受限：模型通常高度依赖于特定的机器人硬件配置，当迁移到不同结构的灵巧手时，往往需要重新采集数据并训练。数据依赖严重：高质量、大规模的人机动作配对数据获取成本极高，且模型容易受到训练数据分布偏差的影响。不可解释性：黑盒化的神经网络难以保证生成的动作始终符合严格的物理

约束，偶尔会出现违反关节限位或产生物理碰撞的非预测行为。

2.4 结合了优化与学习的方法

为了克服纯优化方法易陷入局部最优以及纯学习方法泛化性较差的局限，研究者开始探索将深度学习的感知能力与数值优化的约束处理能力相结合的混合框架。

2.4.1 基本原理

该类方法的核心思想是利用神经网络为优化过程提供高质量的先验知识。通常通过编码器将人类动作映射到低维的隐空间（Latent Space），并在该空间内利用神经网络的输出作为初始值，辅助数值求解器进行迭代优化。其数学本质是利用学习到的运动规律来缩小优化的搜索范围，使求解过程既能快速收敛，又能有效跳出局部极小值的陷阱，从而兼顾了推理效率与平台泛化性[9][10]。

2.4.2 基于图神经网络加速的初始值预测

由于人手与机器人手的拓扑结构具有天然的图属性，部分研究采用图神经网络（GNN）及其变体来提取关节间的空间层级特征。通过改进图卷积算子或引入更灵活的动态图结构，模型能够学习不同自由度之间的协同映射关系，并为优化算法提供极具物理意义的初始关节向量。这种基于图结构的初始值辅助机制显著减少了逆运动学求解所需的迭代次数，在保持高精度的同时提升了系统的实时响应频率。

2.4.3 C3PO

C3PO 是一种典型的三阶段循环优化架构。它首先利用深度网络在隐空间内预测目标姿态的特征表示，随后通过循环一致性约束和几何优化层对结果进行精修。C3PO 的核心贡献在于它将高维的运动空间映射问题转化为隐空间内的特征对齐问题，既保留了学习方法对视觉噪声的容错性，又通过优化闭环确保了生成的动作符合机器人底层的物理拓扑约束。

2.4.4 优缺点

优点：协同优势明显：解决了纯优化方法对“冷启动”初始值的依赖，同时弥补了纯学习方法在推理时间和跨平台部署上的短板。鲁棒性与精度兼备：神经网络提供的全局先验与优化层提供的局部约束相结合，使系统在复杂交互任务中表现更稳健。主流技术趋势：在处理异构灵巧手映射时，展现出了比单一路径更强的适配能力。

缺点：计算时延叠加：尽管优化迭代次数减少，但模型前向传播与求解器运行的总耗时仍不可忽视。时序平滑度缺失：现有的混合方法大多仍采用逐帧（Frame-by-frame）处理逻辑，未能充分利用连续输入帧之间的时空相关信息。由于忽略了帧间依赖关系，在面对视觉抖动或高速运动时，生成的机器人动作序列仍存在连续性不足、不够平滑的问题。

2.5 时间信息的重要性

上述算法和现存的大部分算法都只考虑了输入帧的静态特征，忽略了帧间依赖关系[?]。现有的动捕数据均已能达到较高帧率[]，而连续多帧信息中蕴含的运动趋势特征对于生成平滑、自然的机器人动作序列至关重要。而针对带有噪声的原始动捕数据，基于 Transformer 的编码器-解码器结构可以充当“时空滤波器”，借助连续帧之间的时空相关性，自动滤除非物理的高频抖动，在保持运动意图的同时自动滤除高频抖动[11][12][2]。这一特性正是 TransRetarget 能够解决机器人重定向结果不平滑问题的核心理论基础。

2.6 Transformer 架构简述

Transformer 架构自提出以来，因其卓越的序列建模能力，已成为处理时序数据（如语音、文本及机器人动作序列）的核心技术方案。其核心优势在于摒弃了传统循环神经网络的顺序计算模式，转而采用全局并行的注意力机制。

2.6.1 Transformer 的提出

Transformer 最初由 Vaswani 等人在 2017 年的论文《Attention Is All You Need》中提出。该模型设计的初衷是为了解决 RNN 在处理长序列时存在的梯度消失及计算效率低下的问题。通过完全依赖注意力机制（Attention Mechanism）来建模输入与输出之间的全局依赖关系，Transformer 实现了计算的高度并行化，并展现出极

强的特征提取能力与扩展性（Scalability）。

2.6.2 Transformer 的核心机制：自注意力机制

自注意力机制是 Transformer 的核心灵魂。它通过将输入序列中的每个元素映射为查询向量（Query）、键向量（Key）和值向量（Value），计算序列内各元素之间的相关性得分。

全局建模能力：不同于卷积神经网络（CNN）的局部感受野，自注意力机制允许序列中的任意两个位置直接进行交互，从而能够精准捕捉动作序列中的长距离空间关联与时间依赖。

动态权重分配：模型能够根据当前任务上下文，自动为关键关节或关键帧分配更高的权重，从而在复杂的灵巧操作中聚焦于最重要的运动特征。

2.6.3 Transformer 的核心组件及其作用

一个标准的 Transformer 架构主要由以下关键组件构成：

多头注意力层（Multi-Head Attention）：通过在多个不同的子空间内并行执行自注意力计算，使模型能够同时关注序列中不同维度的特征（例如，一组头关注手指的局部弯曲，另一组头关注手臂的整体位姿），增强了特征提取的丰富度。

位置编码（Positional Encoding）：由于 Transformer 本身不具备处理顺序信息的能力，需要通过位置编码将时序信息（帧的先后顺序）注入到特征向量中。这对于捕获机器人运动的连续性和速度感至关重要。

前馈神经网络（Feed-Forward Network, FFN）：在每个注意力层之后，通过一个逐位置的全连接网络进行非线性变换，进一步增强模型的表达能力，完成从隐特征到动作空间的非线性映射。

残差连接与层归一化（Residual Connection Layer Normalization）：这些组件确保了深层网络在训练过程中的数值稳定性，有效防止了深度模型中常见的退化问题，使得 TransRetarget 等复杂架构能够高效收敛。

2.7 Transformer 架构在人体骨骼点序列中的应用

由于人体骨骼点序列具有显著的空间层级结构和时间演变规律，Transformer 架构凭借其强大的时空特征提取能力，已成为处理此类数据的核心技术。

2.7.1 Transformer 在人体手语识别中的作用

手语识别要求模型能够同时理解精细的手指动作变化、手掌位姿以及手臂的运动轨迹。传统的循环神经网络（RNN）在处理长序列手语时容易丢失早期信息，而 Transformer 通过自注意力机制能够有效捕捉手语动作中的长距离时间动态特征。同时模型能够自动识别动作序列中的“关键词”帧（如手势转折点），并建立不同动作片段之间的语义关联。另外 Transformer 的扩展性允许其将手部骨骼点特征与面部表情、身体姿态等多维度空间特征进行高效融合，显著提升了复杂语境下的手语理解准确率[13]。该应用体现了 Transformer 在处理具有高度空间层级结构和时间依赖性的骨骼点序列时的独特优势：多尺度特征解耦：利用 Transformer 的多头注意力机制，模型可以在不同的注意力头中分别聚焦于全局手臂轨迹与局部手指精细动作。这种多尺度特征提取能力使得模型在面对外观相似但含义截然不同的手语词汇时，具备更强的辨析度。

长程语义建模与动作切分：相比传统的循环神经网络，Transformer 的全局感受野允许其跨越长序列捕捉手势之间的前因后果。这使得模型能够自动对连续手语流进行隐含的动作切分，精准识别出起始帧、过渡帧与结束帧，从而建立起动作片段与语言词义之间的高效映射。

多模态融合的可扩展性：Transformer 架构的 Token 化处理方式使其成为多模态融合的天然载体。除了骨骼点特征，模型可以同步引入面部表情特征向量以及环境上下文信息，通过交叉注意力机制实现多源信息的互补，显著提升了在复杂动态背景下的手语识别稳健性。

2.7.2 Transformer 在 2D 姿态转 3D 姿态中的作用

从单目图像的 2D 骨骼点坐标恢复 3D 空间位姿（Lifting）是一个典型的非线性映射问题。Transformer 在此领域的应用主要体现在解决深度模糊（Depth Ambiguity）上。通过引入时序 Transformer，模型可以利用相邻帧的运动信息来推断当前帧丢失的深度数据。利用注意力机制建模人体关节间的生理约束（如肘部与肩部的联动关系），Transformer 能够生成比逐帧预测更符合人体解剖学的 3D 姿态，为机器人运动重定向提供了高质量的 3D 输入源[14][15]。而在这方面，Transformer 又体现出其他的优势：频域特征与运动平滑性：在时序 Transformer 的基础上，近期的研究开始引入频域分析，通过 Transformer 学习运动序列在频率空间的分量。这不仅能有效滤除 2D 检测器带来的高频噪声，还能确保生成的 3D 轨迹符合人体动力学的平滑性要求，减少了视觉上的抖动。

跨视角一致性约束：Transformer 可以通过自注意力模块建模不同相机视角下的几何关联。即便在单目输入场景下，模型也可以通过预训练学习到多视角下的投影规律，从而在 3D 提升过程中自动补偿因肢体自遮挡而丢失的关节点信息。

解剖学几何先验的隐式表达：借助于 Transformer 对非局部关系的建模能力，模型可以学习到人体骨骼长度固定、关节转动极限等物理约束。这种隐式的几何先验使得生成的 3D 姿态能够严格遵守人体解剖学规范，为后续将人类动作高保真地重定向至机器人平台提供了可靠的数据基础。

2.7.3 Transformer 在动作序列预测与生成中的作用

动作序列预测（Motion Prediction/Generation）旨在根据历史运动轨迹预测未来的动作走向，或根据特定语义生成符合物理规律的连续动作。Transformer 能够学习到复杂动作（如行走、抓取）的内在节奏与惯性规律。通过位置编码（Positional Encoding）注入时序信息，模型可以预测出具有高度平滑性的关节轨迹。在预测这类问题，transformer 又具有以下优势：动作序列的非确定性建模：利用生成式 Transformer（如 GPT 架构或扩散模型 Transformer），系统可以根据当前手势预测出多种可能的后续轨迹。这种生成能力使得重定向算法在处理快速切换的交互动作时，具备一定的“预判”能力，降低了系统的感知时延。

时空特征的循环精修：通过编码器-解码器结构，Transformer 可以对生成的动作序列进行多次迭代精修。在每一轮迭代中，模型都会结合空间上的拓扑约束与时间上的连续性约束，自动修正动作中不自然的关节转角，从而生成符合物理逻辑且视觉自然的运动流。

2.7.4 Transformer 与图神经网络的关系

与图神经网络相比，Transformer 可以被视为一种独特且具有优势的全连接图神经网络[16]。

在传统的图神经网络中，节点之间的消息传递通常是局部的，并高度依赖于预定义的邻接关系[17]。例如，单层图卷积网络仅能感知其直接相邻节点的信息；若要捕捉更高阶的邻域信息，则必须增加网络层数，这不仅提高了计算成本，还需要针对不同的灵巧手数据规格调整架构以维持效率。

相比之下，Transformer 的自注意力机制允许每个节点与图中所有其他节点进行全局交互。这种全局建模能力使 Transformer 在捕获关节间复杂的时空关系方面表现卓越[12]。

需要强调的是，虽然本文算法在功能上等同于全连接图神经网络，但它与具有固定连接关系的图卷积网络不同。Transformer 通过自注意力机制动态地调整节点间的关系权重，这使得模型在面对各种异构灵巧手结构和不同数据输入时具备更强的灵活性。此外，Transformer 非常适用于处理时序数据，并具有极高的可扩展性。

2.8 本章小结

本章首先总结了人机重定向的三种主要方法（优化、学习、混合）及其分析。然后概括了 Transformer 架构及其在骨骼点序列中的具体应用场景。最后指出了现有研究的局限性，为后续章节提供了理论支撑。

第 3 章 基于时空 Transformer 的运动重定向方法

本章将详细介绍本文提出的基于时空 Transformer 架构的人机运动重定向算法——TransRetarget。该算法旨在解决现有重定向方法中存在的帧间动作不连贯、对输入噪声敏感以及跨平台适配困难等核心问题。

3.1 PoseformerV1

作为本论文算法的参考算法，本文将首先介绍 PoseFormerV1 的原理。其主要完成的任务是解析输入的二维关键点序列，并生成相应的三维姿态表示。PoseFormerV1 的整体架构主要由空间 Transformer 编码器和时间 Transformer 编码器级联而成[14][15]，如图3-1 所示。

3.1.1 空间 Transformer 编码器

输入：每一帧内所有人体关节的坐标。处理机制：首先将每个关节坐标线性投影为高维向量，并加入可学习的空间位置嵌入以保留关节类别信息。作用：利用自注意力机制在单帧内捕捉不同关节之间的空间拓扑依赖关系。

3.1.2 时间 Transformer 编码器

输入：将空间编码器输出的每一帧关节特征展平并拼接，转化为帧序列特征。处理机制：加入时间位置嵌入后，在整个时间维度上进行密集建模。作用：学习动作在长距离时间序列中的演变规律和动态特征。

3.1.3 回归头

通过简单的回归头聚合时间信息，并利用线性投影层最终输出中心帧的 3D 姿态表示。

3.1.4 主要优势

打破卷积局限：相比传统的 CNN 方法，PoseFormerV1 能够更好地建模人体关节间的长距离依赖和复杂的时间动态规律。其在 Human3.6M 等权威数据集上取得

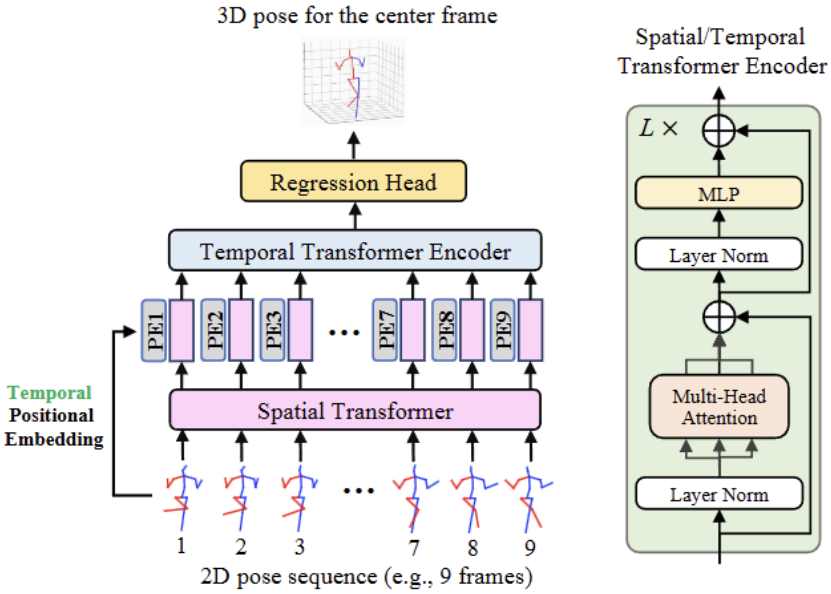

图 3-1 PoseFormerV1 的网络架构示意图。

了领先的预测精度，证明了 Transformer 处理骨骼点序列的有效性。

3.1.5 局限性

尽管 PoseFormerV1 表现优异，但在实际应用中仍面临挑战。其计算开销巨大：由于自注意力机制的计算量随序列长度成平方级增长，处理长序列（如 81 帧以上）时对硬件资源要求极高。

3.2 空间编码器

在本文提出的 TransRetarget 框架中，空间编码器承担着解析单帧手部姿态内部拓扑结构的任务。与原始 PoseFormerV1 处理 2D 像素坐标不同，本文的空间编码器直接作用于三维空间数据，旨在提取更高维度的手部几何特征。

3.2.1 特征线性投影

空间编码器的输入为单帧手部关键点的三维坐标序列。为了使网络能够处理这些原始数值，系统首先通过一个线性投影层将每个关键点的三维坐标映射到高维特征空间。这一过程将离散的物理位置转化为具有丰富语义表达能力的特征向量，为后续的自注意力计算奠定基础。

3.2.2 空间位置嵌入

由于 Transformer 本身无法识别输入序列中不同关键点的物理属性，本文在特征向量中注入了可学习的空间位置嵌入。这一设计确保了模型能够感知手部关节顺序，从而学习到符合人类生理结构的姿态信息。空间编码器的核心是由多个多头自注意力模块组成的层级结构。在该模块中，每个关节特征都会与其他所有关节特征进行交互计算：

3.2.3 空间多头自注意力机制

模型会自动计算关节之间的关联权重，例如在执行抓取动作时，指尖与掌心关键点之间会分配更高的注意力权重。通过层层深入的特征聚合，空间编码器能够提取出超越简单坐标关系的局部运动特征和整体手势语义。

3.3 时间编码器

3.2 节提出的目标区域提取方法可以在均匀性或一致性的前提下将图像目标物体或目标区域分割出来, 若与相邻部分合并则会破坏这种一致性。时间编码器是 TransRetarget 框架中处理时序依赖性的核心模块。它的主要任务是接收空间编码器输出的特征序列，通过建模帧与帧之间的动态演变规律，提取手部运动在时间维度上的深层特征，从而确保重定向生成的动作序列具有物理平滑性。

3.3.1 时间位置嵌入

空间编码器将每一帧的手部空间拓扑结构转化为高维特征向量。时间编码器则将这些连续帧的特征向量重新排列，形成一个具有时间属性的序列。为了使模型能够感知动作发生的先后顺序，本模块在输入端引入了时间位置嵌入。这些位置信息与空间特征相融合，使 Transformer 能够识别出动作的起始、延续与结束。

3.3.2 时间多头自注意力机制

时间编码器采用了多层自注意力机制来捕捉长距离的时间依赖关系。相比于逐帧处理的传统算法，该模块能够同时关注当前帧及其前后多帧的运动上下文：通过计算不同时刻特征之间的注意力权重，模型能够学习到手指弯曲的速度、加速度等高阶运动属性。在输入数据存在微小噪声或视觉遮挡导致关键点跳变时，时间编码器可以利用邻近帧的运动惯性对当前时刻的特征进行修正，从而过滤掉非

物理的高频抖动。

3.3.3 时空特征深度耦合

在该模块中，空间编码器提取的解剖学关联与时间编码器提取的运动趋势得到了深度耦合。这种设计使得模型不再仅仅关注单个静态姿态的还原，而是从全局视角理解一段完整的动作语义。例如，在处理一个完整的“抓取并举起”动作时，时间编码器能够确保指尖在闭合过程中的平滑过渡，以及与手臂抬起动作的时序协同。由于引入了时间编码器，TransRetarget 克服了传统重定向方法中常见的“动作闪烁”问题。通过对多帧信息的整合，系统输出的关节控制指令不再是彼此孤立的点，而是符合动力学规律的连续曲线。这不仅提升了机器人运动的视觉自然度，也有效减轻了物理电机的机械损耗，为实时遥操作提供了更加稳定的控制基准。

3.4 回归头

回归头是 TransRetarget 框架的输出层，负责将时间编码器提取的高维时空特征映射为机器人可执行的关节控制参数。该模块起到了连接深度神经网络特征与物理机器人运动学模型的桥梁作用。

3.4.1 特征聚合与降维

时间编码器输出的特征矩阵包含了多帧手部运动的复杂关联信息。回归头首先通过一个线性投影层或全连接层对这些特征进行空间维度的聚合，提取出与关节角度最为相关的语义分量。这一步骤有效地去除了冗余特征，将抽象的神经元激活值转化为具有明确物理意义的中间向量。

3.4.2 关节角度向量映射

在特征聚合的基础上，回归头利用非线性激活函数与线性映射的组合，将特征向量转换为目标机器人的关节角度向量。该向量的维度与目标灵巧手的自由度数量保持一致。例如，在 Linker 灵巧手平台上，回归头会输出一个 17 维的向量，每一维对应一个特定舵机或电机的目标旋转角度。

3.4.3 物理范围限制与激活设计

为了确保生成的角度向量初步符合硬件规范，回归头在输出层采用了 Sigmoid 或 Tanh 等激活函数，并配合比例缩放系数，将网络输出限制在机器人关节的物理极限范围内。这种预处理机制降低了后续运动学模块在处理越界数据时的计算压力。

3.4.4 对后续运动学模块的支持

回归头输出的关节角度向量是后续前向运动学模块的核心输入。通过将时间编码器捕捉到的平滑时序特征直接转化为角度，回归头确保了生成的指令流不仅在空间上能准确还原人手姿态，在时域上也能保持逻辑一致。这种端到端的映射方式极大地缩短了从视觉感知到动作控制的反馈链路，为实现高频率、低延迟的运动重定向提供了保障。

3.5 运动学模块

运动学模块是连接虚拟算法与物理实体的核心纽带，其主要功能是将回归头输出的关节角度映射为机器人在三维空间中的实际位姿。该模块通过解析标准机器人描述文件，构建出精确的几何变换链。

3.5.1 机器人描述文件解析

系统首先通过读取统一机器人描述格式（URDF）文件来获取目标机器手的物理参数。URDF 文件详细记录了机器人各连杆（Link）的几何尺寸、质量分布，以及各关节（Joint）的父子级层级关系。

位置偏移量：模块从文件中提取相邻关节间的相对平移参数，定义了机械结构的初始骨架。

旋转偏移量：通过读取关节轴线的方向和初始旋转偏置，确定了每个自由度的运动范围和旋转基准。

3.5.2 前向运动学计算

在获取固定结构参数后，运动学模块接收来自回归头的实时关节角度输入。利用前向运动学（FK）算法，系统沿运动链逐级进行齐次变换矩阵的连乘运算：

局部变换：根据当前输入的角度，计算每个关节相对于其父级关节的旋转矩

阵。

全局映射：将所有局部的变换累积，最终推导出各关节相对于机器人手掌基座坐标系的精确三维位置。

3.5.3 实际位置导出与物理校验

该模块最终导出机器手各关键点在空间中的实际坐标。这些坐标不仅用于在仿真环境中实时同步机器人的姿态，还用于计算运动重定向的损失函数。在导出位置的同时，模块会结合 URDF 中的物理限制，校验生成的姿态是否产生自碰撞或超出机械限位。

3.5.4 跨平台适配的灵活性

由于该模块完全基于 URDF 文件驱动，给予了 TransRetarget 展现出的极强的平台适应性。当需要更换实验平台（如从 Linker 手迁移至 Shadow 手）时，仅需加载对应的配置文件，运动学模块即可自动更新所有变换参数，无需重新编写底层计算逻辑。

3.6 损失函数设计

为了引导 TransRetarget 框架学习到既符合物理逻辑又能精准还原人类意图的动作映射，本文设计了一套复合损失函数。该损失函数由四个核心部分组成，分别从局部关节配置、全局末端对齐、空间几何关系以及物理安全性维度对模型进行约束。

3.6.1 手指摆动损失

手指摆动损失主要用于约束机器人关节角度的合理性。该项通过对比人手关键点计算出的参考角度与回归头输出的机器人关节角度，确保每一根手指的运动趋势（如弯曲、伸展或侧向摆动）与人类保持语义一致。这有效防止了机器人关节出现非自然的扭转或违反生理结构的姿态。

$$L_{fv} = \frac{1}{N}\sum_{i=1}^{N}\left\|\frac{\mathbf{v}_i}{\|\mathbf{v}_i\|} - \frac{\hat{\mathbf{v}}_i}{\|\hat{\mathbf{v}}_i\|}\right\|^2. \tag{3.1}$$

3.6.2 手指指尖位置损失

这是衡量重定向精度最直接的指标。该损失项计算经过前向运动学模块导出的机器人指尖三维坐标与经过缩放后的人手对应指尖坐标之间的欧式距离。通过最小化该距离，模型能够确保机器人在执行遥操作任务时，其末端执行器能够精准地到达目标空间位置，为后续的精细操作奠定基础。

$$L_{tv} = \frac{1}{N}\sum_{i=1}^{N}\left\|\frac{\mathbf{t}_i}{\|\mathbf{t}_i\|} - \frac{\hat{\mathbf{t}}_i}{\|\hat{\mathbf{t}}_i\|}\right\|^2. \tag{3.2}$$

3.6.3 手指指尖距离损失

为了提高多指协作任务（如捏取、握持）的成功率，本文引入了指尖距离损失。该项不仅关注单个指尖的绝对位置，还关注不同指尖之间的相对空间距离。例如，当人手执行“对捏”动作时，该损失会强制机器人相应的手指指尖也保持较近的距离。这一设计补偿了单点定位误差带来的干涉或闭合不严问题，显著提升了抓取动作的鲁棒性。

$$L_{td} = \frac{1}{N}\sum_{i=1}^{N}\left\|\mathbf{d}_i - \hat{\mathbf{d}}_i\right\|^2. \tag{3.3}$$

3.6.4 碰撞损失

碰撞损失是确保系统物理安全性的重要保障。该项基于运动学模块导出的各连杆空间位置，计算机器人自身各部件（如相邻手指之间）是否存在空间重叠。当检测到潜在的自碰撞风险时，该损失项会产生极大的惩罚值，引导模型调整关节角度以规避物理干涉。这不仅保护了昂贵的硬件设备免受损坏，也确保了生成的动作序列在现实世界中是可执行且安全的。

$$L_{col} = \sum_{c_{i,j}<c_{min}} -\log(c_{i,j}). \tag{3.4}$$

3.6.5 复合损失函数汇总

最终的总体损失函数由上述四项加权累加而成。通过调整各部分的权重比例，模型能够平衡“位置精度”与“物理平滑性”之间的关系，最终输出一套既精准又平稳的控制指令流。

$$L_{total} = \lambda_{fv}\cdot L_{fv} + \lambda_{tv}\cdot L_{tv} + \lambda_{td}\cdot L_{td} + \lambda_{col}\cdot L_{col}. \tag{3.5}$$

3.7 本章小结

本章阐述了图像局部颜色编辑方法中图像目标区域提取的相关方法，……

第 4 章 实验部分

本章将详细介绍实验的具体配置，并展示 TransRetarget 算法与主流基准方法的对比实验结果，从多平台适配性、数据集质量及核心性能指标等维度进行综合评估。

4.1 实验配置

4.1.1 数据集

实验采用了两个互补的数据集以确保模型的泛化性能：自建 VP 数据集：利用 Apple VisionPro 头显采集，包含实验员佩戴设备时进行的 10 分钟随机手部动作，总计 10,000 帧。该数据集每帧提供 25 个手部关键点的高精度三维坐标，真实反映了人类在自然状态下的交互逻辑。CSL-Daily 手语数据集：为了引入更复杂的语义动作，我们从该数据集中提取了由 3 名志愿者演示的 299 种手语动作，共 6,000 帧。通过 SLAHMR 算法从单目图像中恢复出三维手部姿态，每帧提供 16 个关键点位置数据[18]。

4.1.2 训练设置

算法基于 PyTorch 框架实现[19]。硬件配置为 NVIDIA RTX 3050 Laptop GPU 与 Intel Core i7-12700H CPU。训练过程中使用 Adam 优化器，学习率固定为 1×10^{-4}。

4.1.3 评测指标

不同于传统研究仅使用关节角度误差（难以直观反映交互质量），我们采用了更具物理意义的末端空间位置误差作为核心评价指标。我们利用前向运动学（FK）模块计算灵巧手的指尖位置，并将其缩放至与人手相同的尺度。最终，使用均方误差（MSE）来衡量人手关键点与机器人指尖在三维空间中的距离偏差。

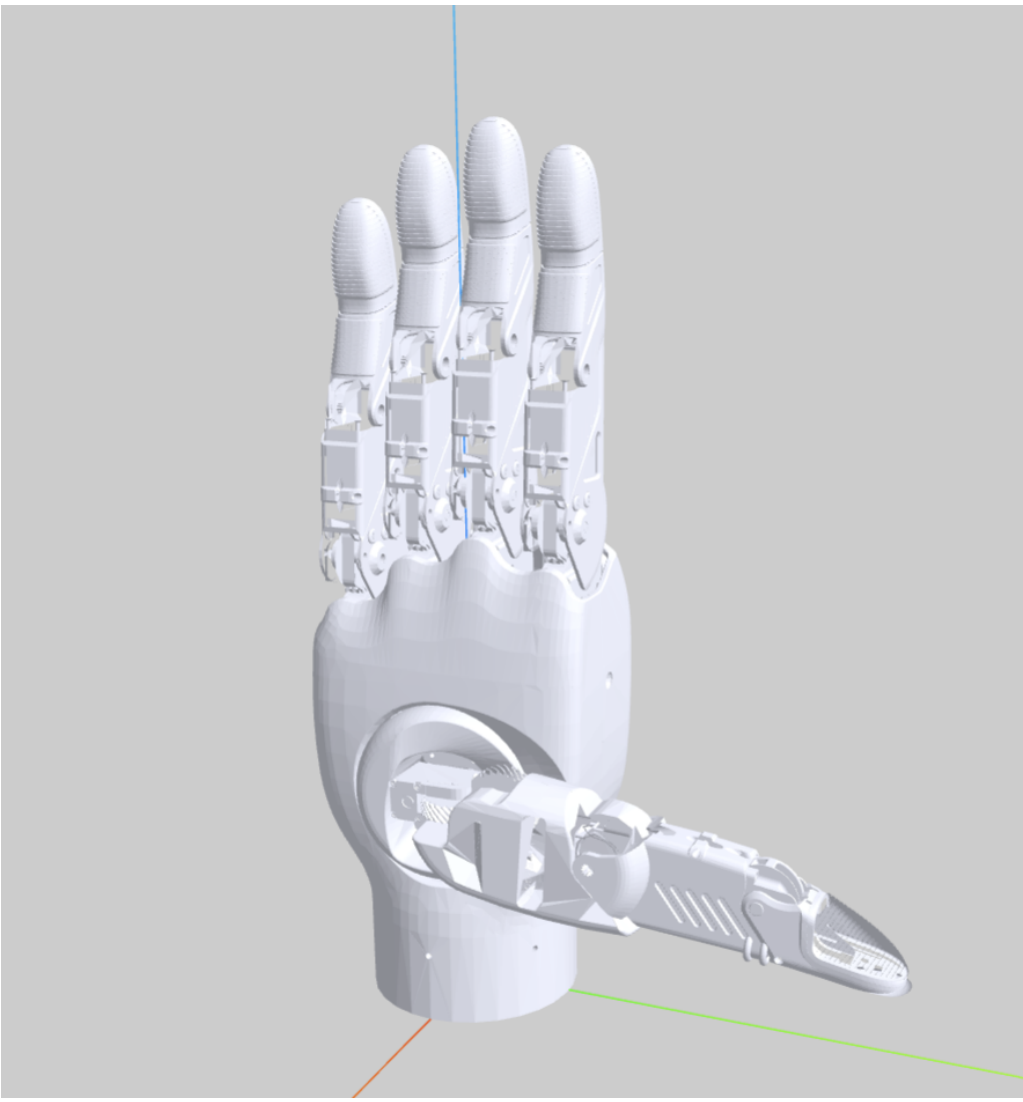

4.1.4 评测平台

4.1.4.1 Linkerhand

平台特性：Linker 灵巧手拥有 17 个自由度（DoF），其设计结构在仿生性与机械复杂性之间取得了平衡，是目前学术界研究中机动性较强的中端灵巧手代表。

4.1.4.2 Shadow Hand

平台特性：Shadow 灵巧手目前是国际上最常用的灵巧手，其结构复杂且具有高度的机械 stiffness，能够处理高自由度的动作。

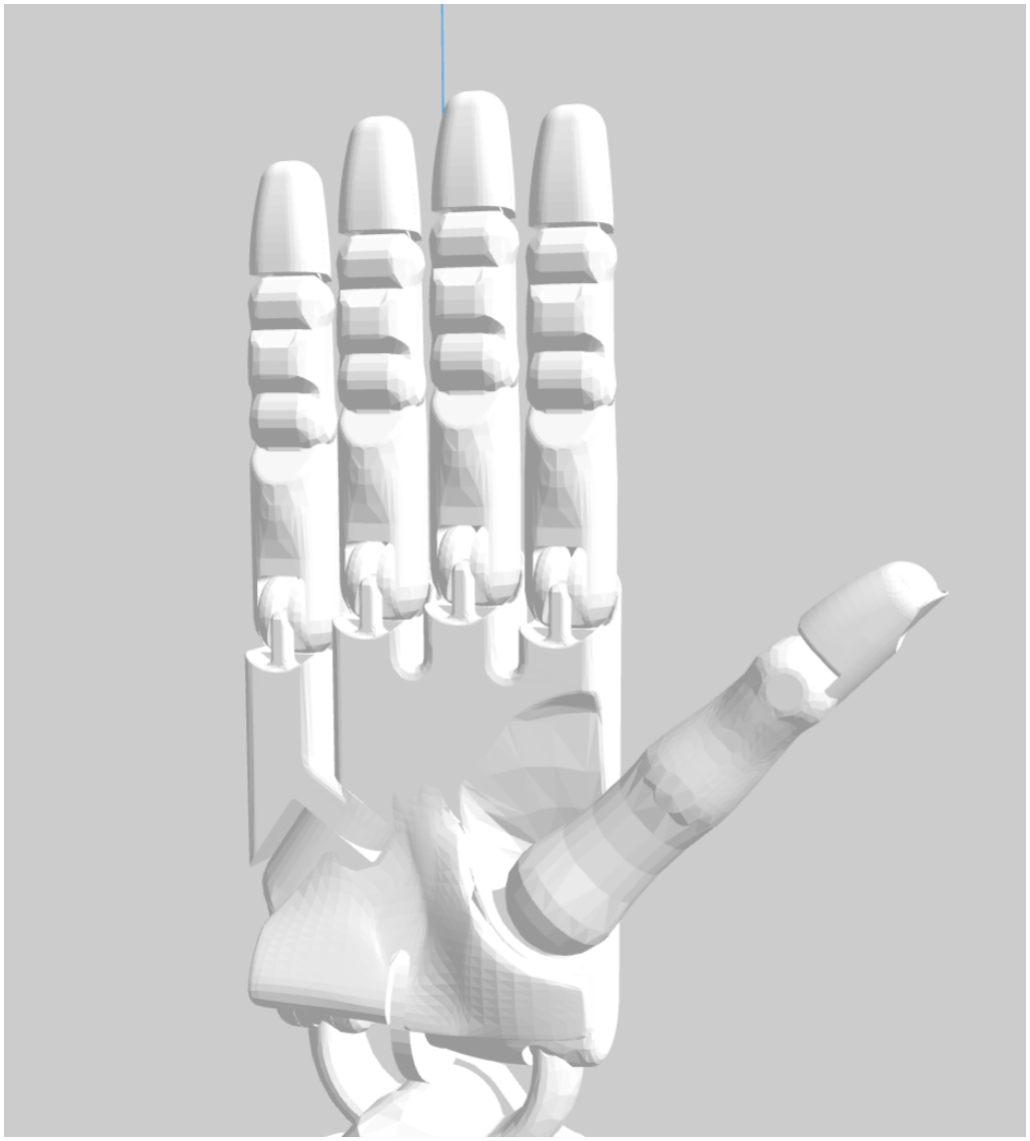

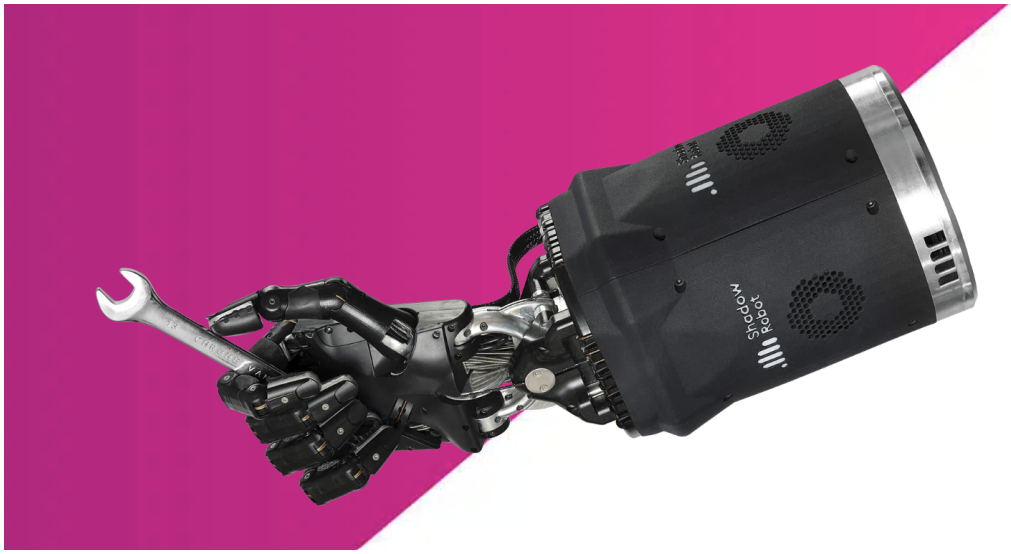
Shadow
Robot

4.1.4.3 Inspire

平台特性：Inspire 灵巧手是国际上最常用的灵巧手，其结构复杂且具有高度的机械 stiffness，能够处理高自由度的动作。

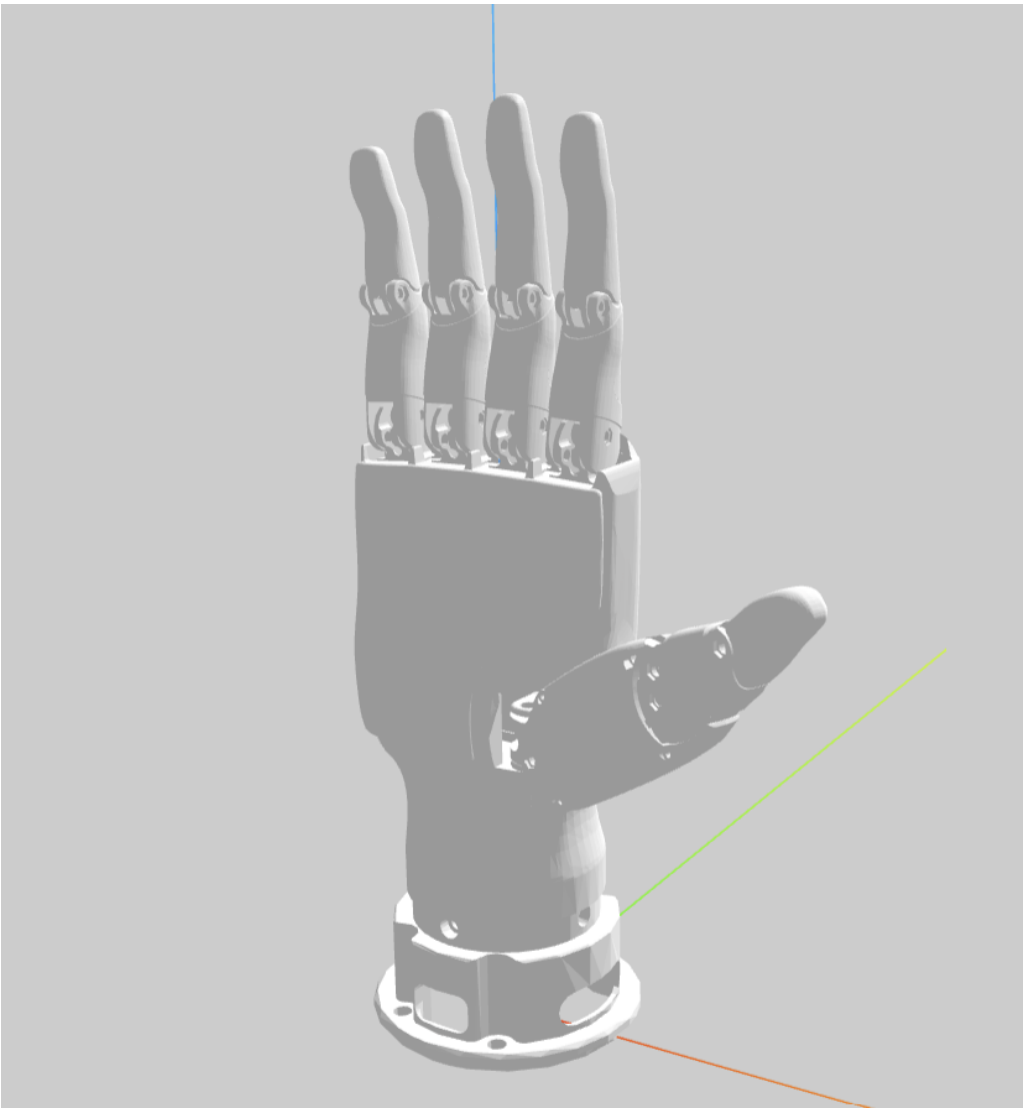

4.2 不同方法的对比实验

我们将 TransRetarget 与两种主流基准算法进行了性能对比：NLO 以及 VMR。

4.2.1 NLO

4.2.2 VMR

4.3 本方法消融实验

为了深入探讨 TransRetarget 框架中各核心组件对重定向性能的具体贡献，本节通过“控制变量法”开展了消融实验。我们通过有针对性地将复合损失函数中的各个子项置零（Ablation），观察其对模型输出精度的影响，从而验证了每一项约束设计的必要性。

4.3.1 Ablation

我们在自建的 VP 数据集上，针对以下四种模型配置进行了对比测试：完整模型 (Full Model)：包含所有设计的损失函数项。置零侧向移动损失 ($L_{abd} = 0$)：移除手指侧向移动的约束。置零弯曲度损失 ($L_{flex} = 0$)：移除手指弯曲程度的物理约束。置零指尖间距损失 ($L_{dist} = 0$)：移除指尖相对距离的空间几何约束。

4.3.2 结果展示

4.3.3 结果分析

消融实验的定量结果如表 **??** 所示。实验数据表明，任何一项损失函数的缺失都会导致重定向性能的下降，具体表现如下：侧向移动约束的重要性：当置零侧向移动损失时，机器人手指在水平面内的定位精度大幅降低。由于灵巧手的侧向自由度通常较少且耦合度高，缺乏该约束会导致模型难以区分复杂抓取动作中的手指张合意图。弯曲度约束对动作自然度的影响：移除弯曲度损失后，虽然指尖可能到达目标位置，但手指的关节配置（Configuration）往往不符合人类的生理习惯，导致生成的动作序列在视觉上显得生硬且不连续，验证了该项在维持人机动作语义一致性上的核心作用。空间几何约束的必要性：指尖间距损失的缺失直接导致了多指协作任务（如捏取小物体）的失败。实验观察到，若不进行间距约束，模型在处理多指靠拢动作时容易产生空间干涉或由于误差累积导致无法闭合。

4.4 Transformer 结构作用可视化

下面将分别给出全局以及局部图像颜色编辑的实验结果对比，并进行分析。……

4.5 多平台实验

为了深入验证 TransRetarget 框架在不同运动学结构与自由度配置下的泛化能力，本节详细介绍了在三款主流灵巧手平台上的部署细节及实验表现。

4.5.1 Linker 灵巧手平台实验

部署表现：得益于 TransRetarget 的时空建模能力，Linker 手在物理实机测试中表现出了极高的轨迹平滑度。即使在传感器采样存在微小噪声的情况下，模型仍能输出连贯的关节控制序列。

实验结论：在 PyBullet 仿真与物理实机的双重验证下，Linker 手在执行握拳、抓取球体等日常动作时，其指尖定位误差（MSE）保持在较低水平，验证了算法从仿真到实机（Sim-to-Real）的平滑迁移能力。

4.5.2 Shadow 灵巧手平台实验

部署表现：在处理拥有 23 个 DoF 的 Shadow 手时，TransRetarget 展现出了强大的高维空间特征提取能力。实验结果显示，模型能够精准捕捉到人类大拇指的对掌动作（Opposability）以及小指的协同运动。

性能差异：相比于其他平台，Shadow 手由于自由度密度极高，传统的单帧学习方法极易产生关节间的物理干涉。而我们的方法通过复合损失函数约束，确保了在如此高维的动作空间中仍能保持指尖轨迹的精确对齐。

4.5.3 Inspire 灵巧手平台实验

部署表现：在仿真测试中，TransRetarget 成功处理了这种“欠驱动”式映射（即人手 20+ 自由度映射至机器人 13 自由度）。算法通过时空 Transformer 学习到的运动先验，自动滤除了无法被机器人执行的细微人类震颤，从而输出了极其稳定的控制轨迹。

性能差异：由于 Inspire 手结构简单，其重定向后的运动响应速度最快，计算时延进一步降低，非常适合作为低功耗、高频交互场景下的首选验证平台。

4.5.4 多平台实验结论

通过对上述三款异构平台的对比分析，实验结果表明：

结构鲁棒性：TransRetarget 在面对自由度从 13 到 23 不等的机器人时，均能维持一致的映射精度。

精度与灵活度的权衡：自由度越高的平台（如 Shadow Hand），虽然映射难度增加，但能够还原更丰富的人类手势细节；而低自由度平台（如 Inspire Hand）则在动作平滑度上表现更佳。

通用性验证：这种跨平台的成功部署，有力证明了本文算法并非针对特定硬件过拟合，而是具备广泛应用价值的具身智能基础设施。

4.6 单机现实世界测试

为了进一步验证 TransRetarget 算法在真实物理环境中的作业能力，本文搭建了一套完整的单机遥操作实验系统，并在现实场景下开展了多目标物体抓取实验。本节旨在测试算法在面对复杂物理交互、物体遮挡及传感器噪声时的鲁棒性。

4.6.1 实验环境构建

实验硬件由 Linker 灵巧手、单目 RGB 摄像头以及计算工作站组成。操作员在摄像头视野范围内进行自然手部动作，算法实时捕捉手姿态并生成重定向指令，驱动物理实体灵巧手执行相应动作。

4.6.2 实验对象与任务设计

我们从日常生活中选取了 6 种具有代表性的物体开展抓取实验，这些物体涵盖了不同的几何形状、尺寸及物理特性：

软质球体（塑料芒果）：测试算法对球形包络抓取的准确性。

细长圆柱体（螺栓）：测试对小直径物体的精密对齐能力。

几何立方体（魔方）：验证算法对规则棱角物体的指尖接触稳定性。

不规则轻质物体（水瓶）：测试在物体发生微小位移时动作的自适应性。

扁平物体（螺母）：挑战算法对精细捏取动作的还原度。

易碎/软质结构（纸杯）：观察生成的运动序列是否足够平滑，以避免由于瞬间冲力导致物体受损。

4.6.3 实验结果分析

实验过程中，每一类物体均进行了 10 次重复抓取测试。实验结果显示：

高成功率与稳定性：在所有 60 次抓取尝试中，系统保持了极高的成功率。受益于 TransRetarget 提取的时空特征，物理机械手在接近物体阶段表现出极佳的轨迹平滑性，有效避免了因动作抖动导致的碰撞偏移。

语义一致性表现：在抓取卡片等细小物体时，算法能够精准复现人类操作员的“指尖对捏”意图，而非简单的“全手合拢”，这得益于复合损失函数对指尖间距的严格约束。

抗噪能力验证：在现实光照变化及背景干扰下，由于 Transformer 具备处理长序列关联的能力，单帧的视觉识别跳变被有效地过滤在时域特征之外，确保了物理电机的平稳运行，显著降低了机械磨损。

4.6.4 实验小结

现实世界抓取实验证明，TransRetarget 不仅在仿真评估中表现优异，在复杂的物理交互场景中同样具备极强的实用性。其生成的动作序列兼具“精准度”与“平滑度”，为具身智能终端在家庭或工业环境中的灵巧操作提供了坚实的技术支撑。

4.7 本章小结

本章详细阐述了本文提出的基于时空 Transformer 架构的人机运动重定向算法 TransRetarget。针对现有重定向方法存在的帧间动作不连贯、对输入噪声敏感及跨平台适配困难等核心问题，本章构建了完整的端到端算法框架。首先，在深入分析 PoseFormerV1 架构及其局限性的基础上，设计了专用的空间编码器与时间编码器。空间编码器利用特征线性投影与多头自注意力机制，精准提取单帧手部姿态的内部拓扑结构与几何特征；时间编码器则通过时序位置嵌入与长距离依赖建模，有效过滤高频抖动并确保动作序列的物理平滑性与时序一致性。其次，本章介绍了回归头模块，其负责将高维时空特征映射为符合机器人物理极限的关节角度向量。结合基于 URDF 解析的运动学模块，系统实现了从虚拟姿态到物理实体位姿的精确转换，并具备良好的跨平台适配能力。最后，设计了一套复合损失函数，涵盖手指摆动、指尖位置、指尖距离及碰撞损失四个维度，从局部配置到全局安全性全方位引导模型优化。本章所提出的理论模型与算法设计，解决了异构手映射的关键难题，为后续章节的系统实现与实验验证奠定了坚实的理论与技术基础。

第 5 章 重定向后的交互强化

5.1 直接重定向结果的缺陷

本文针对机器人灵巧遥操作中运动重定向的平滑性、精准性以及跨平台通用性问题，提出了基于时空 Transformer 的运动重定向框架 TransRetarget。通过理论研究、算法设计与多平台实验验证，本文的主要工作总结如下：

构建了高效的时空特征提取架构：借鉴 PoseFormer 的分级建模思想，设计了专门针对手部三维骨骼序列的空间编码器与时间编码器。空间编码器利用自注意力机制捕获单帧内指尖与掌心间的复杂拓扑关系；时间编码器则通过对连续多帧数据的时域建模，提取运动趋势特征，有效解决了传统方法中常见的动作抖动与不连贯问题。

设计了多维度物理约束损失函数：为了平衡运动的保真度与物理安全性，本文设计了包含手指摆动、指尖位置、指尖间距以及碰撞惩罚在内的复合损失函数。该设计确保了重定向结果不仅在空间坐标上精准还原人手意图，且在运动学配置上符合机器人硬件的物理限位，显著提升了多指协作抓取的稳定性。

实现了跨平台的灵巧手适配能力：通过引入基于 URDF 解析的通用运动学模块，本文算法成功在 13 自由度的 Inspire 手、17 自由度的 Linker 手以及 23 自由度的 Shadow 手上完成了部署。实验结果表明，该框架能够自动适配不同自由度分布的机器人硬件，具有极强的泛化性能。

验证了现实场景的实用价值：通过单机现实世界实验，验证了算法在处理 6 种不同几何特性物体抓取任务时的鲁棒性。在 60 FPS 的实时处理速度下，系统能够平滑、精准地复现人类操作员的精细捏取与握持动作，为低延迟遥操作任务提供了可靠的技术支撑。

5.2 基于 VLM 的目标抓取力预测

5.3 基于力矩反馈的强化学习

尽管本文在运动重定向的平滑度与跨平台迁移方面取得了阶段性成果，但面对更加复杂、多变的真实交互场景，仍有以下方向值得进一步探索：

引入频域优化提升长序列处理能力：目前的时域自注意力机制在处理极长序

列时计算开销较大。未来可尝试引入频域特征提取（如离散余弦变换等）来捕捉周期性或快速变化的运动特征，在保持鲁棒性的同时进一步降低计算复杂度。

增强力反馈与物理交互感知：目前的重定向主要基于位置映射。后续研究可考虑将末端执行器的力矩信息或触觉反馈融入损失函数，实现具备“触感”的运动重定向，从而在处理易碎物体或需要恒力交互的任务中表现得更加出色。

大模型先验知识的注入：探索将预训练的视觉-语言大模型或通用的具身智能大模型作为特征提取的先验，使重定向系统能够理解更高层次的动作语义（如“递给”、“旋转”），从而在传感器数据缺失或遮挡严重的情况下实现智能化的动作补全。

全臂-手协同的重定向研究：目前的重点在于灵巧手部。未来将尝试将该框架扩展至全臂与灵巧手协同的重定向任务中，解决人体手臂与机器人机械臂之间的工作空间映射问题，实现更加自然、直观的全身遥操作体验。

第 6 章 总结与展望

6.1 工作总结

本文针对机器人灵巧遥操作中运动重定向的平滑性、精准性以及跨平台通用性问题，提出了基于时空 Transformer 的运动重定向框架 TransRetarget。通过理论研究、算法设计与多平台实验验证，本文的主要工作总结如下：

构建了高效的时空特征提取架构：借鉴 PoseFormer 的分级建模思想，设计了专门针对手部三维骨骼序列的空间编码器与时间编码器。空间编码器利用自注意力机制捕获单帧内指尖与掌心间的复杂拓扑关系；时间编码器则通过对连续多帧数据的时域建模，提取运动趋势特征，有效解决了传统方法中常见的动作抖动与不连贯问题。

设计了多维度物理约束损失函数：为了平衡运动的保真度与物理安全性，本文设计了包含手指摆动、指尖位置、指尖间距以及碰撞惩罚在内的复合损失函数。该设计确保了重定向结果不仅在空间坐标上精准还原人手意图，且在运动学配置上符合机器人硬件的物理限位，显著提升了多指协作抓取的稳定性。

实现了跨平台的灵巧手适配能力：通过引入基于 URDF 解析的通用运动学模块，本文算法成功在 13 自由度的 Inspire 手、17 自由度的 Linker 手以及 23 自由度的 Shadow 手上完成了部署。实验结果表明，该框架能够自动适配不同自由度分布的机器人硬件，具有极强的泛化性能。

验证了现实场景的实用价值：通过单机现实世界实验，验证了算法在处理 6 种不同几何特性物体抓取任务时的鲁棒性。在 60 FPS 的实时处理速度下，系统能够平滑、精准地复现人类操作员的精细捏取与握持动作，为低延迟遥操作任务提供了可靠的技术支撑。

6.2 研究展望

尽管本文在运动重定向的平滑度与跨平台迁移方面取得了阶段性成果，但面对更加复杂、多变的真实交互场景，仍有以下方向值得进一步探索：

引入频域优化提升长序列处理能力：目前的时域自注意力机制在处理极长序列时计算开销较大。未来可尝试引入频域特征提取（如离散余弦变换等）来捕捉周期性或快速变化的运动特征，在保持鲁棒性的同时进一步降低计算复杂度。

增强力反馈与物理交互感知：目前的重定向主要基于位置映射。后续研究可考虑将末端执行器的力矩信息或触觉反馈融入损失函数，实现具备“触感”的运动重定向，从而在处理易碎物体或需要恒力交互的任务中表现得更加出色。

大模型先验知识的注入：探索将预训练的视觉-语言大模型或通用的具身智能大模型作为特征提取的先验，使重定向系统能够理解更高层次的动作语义（如“递给”、“旋转”），从而在传感器数据缺失或遮挡严重的情况下实现智能化的动作补全。

全臂-手协同的重定向研究：目前的重点在于灵巧手部。未来将尝试将该框架扩展至全臂与灵巧手协同的重定向任务中，解决人体手臂与机器人机械臂之间的工作空间映射问题，实现更加自然、直观的全身遥操作体验。

参考文献

[1] O'NEILL A, REHMAN A, MADDUKURI A, et al. Open X-Embodiment: Robotic Learning Datasets and Rt-x Models: Open x-Embodiment Collaboration 0[C] // 2024 IEEE International Conference on Robotics and Automation (ICRA). [S.l.] : IEEE, 2024 : 6892 – 6903.

[2] BROHAN A, BROWN N, CARBAJAL J, et al. Rt-1: Robotics Transformer for Real-World Control at Scale[J]. arXiv preprint arXiv:2212.06817, 2022.

[3] QIN Y, YANG W, HUANG B, et al. Anyteleop: A General Vision-Based Dexterous Robot Arm-Hand Teleoperation System[J]. arXiv preprint arXiv:2307.04577, 2023.

[4] FIGUERA X, PARK S, AHN H. Redefining Data Pairing for Motion Retargeting Leveraging a Human Body Prior[C] // 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). [S.l.] : IEEE, 2024 : 4800 – 4807.

[5] ZHANG H, LI W, LIU J, et al. Kinematic Motion Retargeting via Neural Latent Optimization for Learning Sign Language[J]. IEEE Robotics and Automation Letters, 2022, 7(2) : 4582 – 4589.

[6] VASWANI A, SHAZEER N, PARMAR N, et al. Attention Is All You Need[J]. Advances in neural information processing systems, 2017, 30.

[7] LI S, HENDRICH N, LIANG H, et al. A Dexterous Hand-Arm Teleoperation System Based on Hand Pose Estimation and Active Vision[J]. IEEE Transactions on Cybernetics, 2022, 54(3) : 1417 – 1428.

[8] LAI Y, GAO Q, LIANG Z, et al. DexTele: A Dual-Arm Dexterous Teleoperation System Based on Motion Retargeting and Adaptive Force Control[C] // 2026 IEEE International Conference on Robotics and Automation (ICRA). [S.l.] : IEEE, 2026.

[9] ZHANG M, GAO Q, LAI Y, et al. HR-GCN: 2D-3D Whole-Body Pose Estimation with High-Resolution Graph Convolutional Network from a Monocular Camera[J]. IEEE Sensors Journal, 2025.

[10] DING R, QIN Y, ZHU J, et al. Bunny-Visionpro: Real-time Bimanual Dexterous Teleoperation for Imitation Learning[C] // 2025 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). [S.l.] : IEEE, 2025 : 12248 – 12255.

[11] JIANG B, CHEN X, LIU W, et al. Motiongpt: Human Motion as a Foreign Language[J]. Advances in Neural Information Processing Systems, 2023, 36 : 20067 – 20079.

[12] RAMPášEK L, GALKIN M, DWIVEDI V P, et al. Recipe for a General, Powerful, Scalable Graph Transformer[J]. Advances in Neural Information Processing Systems, 2022, 35 : 14501 – 14515.

[13] CAMGOZ N C, KOLLER O, HADFIELD S, et al. Sign Language Transformers: Joint End-to-End Sign Language Recognition and Translation[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020 : 10023 – 10033.

[14] ZHENG C, ZHU S, MENDIETA M, et al. 3d Human Pose Estimation with Spatial and Temporal Transformers[C] // Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021 : 11656 – 11665.

[15] ZHAO Q, ZHENG C, LIU M, et al. Poseformerv2: Exploring Frequency Domain for Efficient and Robust 3d Human Pose Estimation[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023 : 8877 – 8886.

[16] JOSHI C K. Transformers Are Graph Neural Networks[J]. arXiv preprint arXiv:2506.22084, 2025.

[17] FEY M, LENSSEN J E. Fast Graph Representation Learning with PyTorch Geometric[J]. arXiv preprint arXiv:1903.02428, 2019.

[18] ZHOU H, ZHOU W, QI W, et al. Improving Sign Language Translation with Monolingual Data by Sign Back-Translation[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021 : 1316 – 1325.

[19] IMAMBI S, PRAKASH K B, KANAGACHIDAMBARESAN G R. PyTorch[G] // Programming with TensorFlow: Solution for Edge Computing Applications. [S.l.] : Springer, 2021 : 87 – 104.

致谢

（谢辞应以简短的文字对课题研究与论文撰写过程中曾直接给予帮助的人员(例如指导教师、答疑教师及其他人员) 表示对自己的谢意，这不仅是一种礼貌，也是对他人劳动的尊重，是治学者应当遵循的学术规范。内容限一页。）

姓名

2026 年 3 月 25 日